

Tercer Trabajo Estadística II

Correlación y Regresión Múltiple

Integrantes:

1. Juan David Mena Gamboa
2. Luis Angel Bolaño Lopez
3. Heyner

17 de noviembre de 2025

1. Análisis de Correlación

Utilizando el conjunto de datos de la Gran Encuesta Integrada de Hogares (GEIH) 2024 del DANE, se realizó un análisis de correlación y regresión múltiple. El conjunto de datos incluye las siguientes variables:

Variables cuantitativas analizadas:

- *Valor mensual por prácticas o pasantías* (P3087S1): Variable que registra el valor mensual de estas actividades (variable respuesta Y en el modelo de regresión).
- *Ahorro por cultivar* (P3094S3): Variable que mide los ingresos netos obtenidos por actividades de cultivo (variable explicativa X_1).
- *Ahorro por criar animales* (P3095S3): Variable que mide los ingresos netos obtenidos por la cría de animales (variable explicativa X_2).

Variable cualitativa analizada:

- *¿Fue a reuniones familiares durante las últimas 4 semanas?* (P3101): Variable categórica binaria (Sí/No). Esta variable se analiza mediante comparación de medias entre grupos (quienes asistieron vs quienes no asistieron a reuniones familiares) para cada una de las variables cuantitativas, utilizando pruebas de significancia apropiadas (prueba t de Student o prueba de Mann-Whitney según el cumplimiento de supuestos de normalidad).

1.1 Pruebas de Significancia de Correlación

Para cada par de variables se plantearon las hipótesis y se ejecutaron las pruebas de significancia correspondientes utilizando el coeficiente de correlación de Pearson.

Relación 1: Valor mensual por prácticas vs Ahorro por cultivar

- *Planteamiento del problema:* Se busca determinar si existe una relación lineal entre el valor mensual por prácticas o pasantías y el ahorro generado por actividades de cultivo en los hogares colombianos.
- Hipótesis: $H_0 : \rho = 0$ (no hay correlación lineal) $H_1 : \rho \neq 0$ (hay correlación lineal)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Coeficiente de correlación de Pearson

Estadístico Empleado	Correlación de Pearson
Fórmula del estadístico	$t = r \sqrt{\frac{n-2}{1-r^2}}$
Nombre Parámetro	Valor
Coeficiente de correlación (r)	0.3295
Estadístico t	7.7872
Grados de libertad (df)	498
Tamaño de muestra (n)	500
Valor-p	$4,00 \times 10^{-14}$

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$ o si $|t| > t_{\alpha/2, n-2}$
- Decisión: Rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, la evidencia sugiere que existe una correlación positiva moderada ($r = 0,3295$) entre el valor mensual por prácticas o pasantías y el ahorro generado por actividades de cultivo en los hogares colombianos. Esta relación indica que, en promedio, los hogares que reportan mayores valores mensuales por prácticas o pasantías tienden a tener también mayores ahorros por actividades de cultivo, lo cual podría reflejar que ambos indicadores están relacionados con el nivel de recursos económicos del hogar o con estrategias de diversificación de ingresos. La fuerza de la correlación es moderada ($0,3 \leq |r| < 0,7$), lo que indica una relación lineal de intensidad media entre estas variables.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de correlación?: Sí, existe evidencia estadísticamente significativa de correlación (p-valor $< 0,001$).
 - ¿En qué dirección?: La correlación es positiva, lo que significa que a medida que aumenta el valor mensual por prácticas, también aumenta el ahorro por cultivar.
 - ¿Es débil, moderada o fuerte?: La correlación es moderada ($|r| = 0,3295$), lo que indica una relación lineal de intensidad media entre estas variables económicas.

Relación 2: Valor mensual por prácticas vs Ahorro por criar animales

- *Planteamiento del problema:* Se busca determinar si existe una relación lineal entre el valor mensual por prácticas o pasantías y el ahorro generado por la cría de animales en los hogares colombianos.
- Hipótesis: $H_0 : \rho = 0$ (no hay correlación lineal) $H_1 : \rho \neq 0$ (hay correlación lineal)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Coeficiente de correlación de Pearson

Estadístico Empleado	Correlación de Pearson
Fórmula del estadístico	$t = r \sqrt{\frac{n-2}{1-r^2}}$
Nombre Parámetro	Valor
Coeficiente de correlación (r)	0.2226
Estadístico t	5.0962
Grados de libertad (df)	498
Tamaño de muestra (n)	500
Valor-p	$4,93 \times 10^{-7}$

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$ o si $|t| > t_{\alpha/2, n-2}$
- Decisión: Rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, la evidencia sugiere que existe una correlación positiva débil ($r = 0,2226$) entre el valor mensual por prácticas o pasantías y el ahorro generado por la cría de animales en los hogares colombianos. Esta relación indica que, en promedio, los hogares que reportan mayores valores mensuales por prácticas o pasantías tienden a tener también mayores ahorros por la cría de animales, aunque esta asociación es menos fuerte que la observada con el ahorro por cultivar. Esta relación podría reflejar que ambas actividades económicas están relacionadas con el nivel de recursos del hogar, pero la cría de animales podría estar más asociada con contextos rurales o periurbanos específicos, mientras que las prácticas tienen una distribución más amplia. La fuerza de la correlación es débil ($0,1 \leq |r| < 0,3$), lo que indica una relación lineal de baja intensidad entre estas variables.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de correlación?: Sí, existe evidencia estadísticamente significativa de correlación (p-valor $< 0,001$).
 - ¿En qué dirección?: La correlación es positiva, lo que significa que a medida que aumenta el valor mensual por prácticas, también aumenta el ahorro por criar animales.
 - ¿Es débil, moderada o fuerte?: La correlación es débil ($|r| = 0,2226$), lo que indica una relación lineal de baja intensidad entre estas variables económicas.

Relación 3: Ahorro por cultivar vs Ahorro por criar animales

- *Planteamiento del problema:* Se busca determinar si existe una relación lineal entre el ahorro generado por actividades de cultivo y el ahorro generado por la cría de animales en los hogares colombianos.
- Hipótesis: $H_0 : \rho = 0$ (no hay correlación lineal) $H_1 : \rho \neq 0$ (hay correlación lineal)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Coeficiente de correlación de Pearson

Estadístico Empleado	Correlación de Pearson
Fórmula del estadístico	$t = r \sqrt{\frac{n-2}{1-r^2}}$
Nombre Parámetro	Valor
Coeficiente de correlación (r)	0.1344
Estadístico t	3.0257
Grados de libertad (df)	498
Tamaño de muestra (n)	500
Valor-p	$2,61 \times 10^{-3}$

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$ o si $|t| > t_{\alpha/2, n-2}$
- Decisión: Rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, la evidencia sugiere que existe una correlación positiva débil ($r = 0,1344$) entre el ahorro generado por actividades de cultivo y el ahorro generado por la cría de animales en los hogares colombianos. Esta relación indica que, en promedio, los hogares que reportan mayores ahorros por cultivar tienden a tener también mayores ahorros por criar animales, aunque esta asociación es muy débil. Esta relación podría reflejar que ambos tipos de actividades agropecuarias están presentes en hogares rurales que diversifican sus fuentes de ingresos, pero la baja correlación sugiere que estos son estrategias económicas que pueden funcionar de manera relativamente independiente. La fuerza de la correlación es débil ($0,1 \leq |r| < 0,3$), lo que indica una relación lineal de baja intensidad entre estas variables. La baja correlación entre estas dos variables explicativas es favorable para el modelo de regresión múltiple, ya que reduce el riesgo de multicolinealidad.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de correlación?: Sí, existe evidencia estadísticamente significativa de correlación (p-valor = 0.0026).
 - ¿En qué dirección?: La correlación es positiva, lo que significa que a medida que aumenta el ahorro por cultivar, también aumenta el ahorro por criar animales.
 - ¿Es débil, moderada o fuerte?: La correlación es débil ($|r| = 0,1344$), lo que indica una relación lineal de baja intensidad entre estas variables económicas. Esta baja correlación es beneficiosa para el modelo de regresión múltiple, ya que reduce el riesgo de problemas de multicolinealidad entre las variables explicativas.

1.2 Matriz de Correlación

A continuación se presentan las representaciones gráficas de las correlaciones entre las variables analizadas. La Figura 1 muestra la matriz de correlación de Pearson entre las tres variables analizadas.




Figura 1: Matriz de Correlación de Pearson

En la Figura 1 se observa que todos los coeficientes de correlación son positivos, lo cual indica relaciones directas entre las variables. Los colores más intensos (rojos más oscuros) representan correlaciones más fuertes. La correlación más fuerte es la que existe entre el valor mensual por prácticas y el ahorro por cultivar ($r = 0.330$), seguida por la correlación entre el valor mensual por prácticas y el ahorro por criar animales ($r = 0.223$). La correlación más débil es la que existe entre las dos variables explicativas, ahorro por cultivar y ahorro por criar animales ($r = 0.134$), lo cual es favorable para evitar problemas de multicolinealidad en el modelo de regresión.

La Figura 2 presenta la matriz de dispersión que incluye diagramas de dispersión entre pares de variables y las distribuciones marginales de cada variable en la diagonal.

Matriz de Dispersión y Correlaciones




Figura 2: Matriz de Dispersión y Correlaciones

En la Figura 2 se observan los diagramas de dispersión entre cada par de variables, los cuales muestran tendencias positivas en todas las relaciones, confirmando las correlaciones positivas encontradas. En la diagonal se presentan las distribuciones de frecuencia de cada variable, las cuales muestran distribuciones sesgadas hacia la derecha, característica común en variables económicas que representan valores monetarios. Este patrón indica que la mayoría de los hogares tienen valores relativamente bajos en estas variables, mientras que algunos hogares presentan valores considerablemente más altos, lo cual es consistente con la distribución típica de ingresos y ahorros en poblaciones económicas.

1.3 Análisis Comparativo con Variable Cualitativa: Reuniones Familiares

Para analizar la asociación entre la variable cualitativa P3101 (¿Fue a reuniones familiares durante las últimas 4 semanas?) y las variables cuantitativas, se realizó un análisis

comparativo de medias entre los dos grupos (Sí vs No) para cada variable cuantitativa. Dado que la correlación de Pearson requiere variables continuas, se utilizaron pruebas de comparación de medias (prueba t de Student o prueba de Mann-Whitney según el cumplimiento de supuestos de normalidad).

Relación 4: Valor mensual por prácticas vs Reuniones familiares

- *Planteamiento del problema:* Se busca determinar si existe una diferencia significativa en el valor mensual por prácticas o pasantías entre las personas que asistieron a reuniones familiares y las que no asistieron.
- Hipótesis: $H_0 : \mu_{\text{Sí}} = \mu_{\text{No}}$ (no hay diferencia entre grupos) $H_1 : \mu_{\text{Sí}} \neq \mu_{\text{No}}$ (hay diferencia entre grupos)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba de Mann-Whitney (U de Wilcoxon)

Estadístico Empleado	Prueba de Mann-Whitney (U de Wilcoxon)
Nombre Parámetro	Valor
Grupo 'Sí' (asistió a reuniones familiares): n	4
Grupo 'Sí': Media	986,250
Grupo 'No' (no asistió a reuniones familiares): n	332
Grupo 'No': Media	998,858.4
Diferencia de medias (Sí - No)	-12,608.43
Estadístico U (Mann-Whitney)	651
Valor-p	0.948

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: No rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, no hay evidencia estadísticamente significativa de diferencia en el valor mensual por prácticas o pasantías entre las personas que asistieron a reuniones familiares (media = 986,250) y las que no asistieron (media = 998,858.4). La diferencia observada (-12,608.43) no es estadísticamente significativa (p-valor = 0.948). Esto indica que la asistencia a reuniones familiares no está asociada con diferencias en el valor mensual por prácticas o pasantías.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de asociación?: No, no hay evidencia estadísticamente significativa de asociación (p-valor = 0.948 $> 0,05$).
 - ¿En qué dirección?: Sin diferencia significativa (la diferencia observada no es estadísticamente significativa).
 - ¿Es débil, moderada o fuerte?: Sin efecto (no hay diferencia significativa entre grupos).

Relación 5: Ahorro por cultivar vs Reuniones familiares

- *Planteamiento del problema:* Se busca determinar si existe una diferencia significativa en el ahorro por cultivar entre las personas que asistieron a reuniones familiares y las que no asistieron.
- Hipótesis: $H_0 : \mu_{Si} = \mu_{No}$ (no hay diferencia entre grupos) $H_1 : \mu_{Si} \neq \mu_{No}$ (hay diferencia entre grupos)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba de Mann-Whitney (U de Wilcoxon)

Estadístico Empleado	Prueba de Mann-Whitney (U de Wilcoxon)
Nombre Parámetro	Valor
Grupo 'Sí' (asistió a reuniones familiares): n	355
Grupo 'Sí': Media	107,085.9
Grupo 'No' (no asistió a reuniones familiares): n	2,537
Grupo 'No': Media	129,715.4
Diferencia de medias (Sí - No)	-22,629.47
Estadístico U (Mann-Whitney)	426,349
Valor-p	0.103

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: No rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, no hay evidencia estadísticamente significativa de diferencia en el ahorro por cultivar entre las personas que asistieron a reuniones familiares (media = 107,085.9) y las que no asistieron (media = 129,715.4). Aunque se observa una diferencia numérica (-22,629.47) donde el grupo que no asistió tiene un mayor ahorro promedio, esta diferencia no es estadísticamente significativa (p-valor = 0.103). Esto indica que la asistencia a reuniones familiares no está asociada con diferencias significativas en el ahorro por cultivar.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de asociación?: No, no hay evidencia estadísticamente significativa de asociación (p-valor = 0.103 $> 0,05$).
 - ¿En qué dirección?: Sin diferencia significativa (aunque hay una diferencia numérica donde el grupo 'No' tiene mayor media, esta diferencia no es estadísticamente significativa).
 - ¿Es débil, moderada o fuerte?: Sin efecto (no hay diferencia significativa entre grupos).

Relación 6: Ahorro por criar animales vs Reuniones familiares

- *Planteamiento del problema:* Se busca determinar si existe una diferencia significativa en el ahorro por criar animales entre las personas que asistieron a reuniones familiares y las que no asistieron.
- Hipótesis: $H_0 : \mu_{\text{Sí}} = \mu_{\text{No}}$ (no hay diferencia entre grupos) $H_1 : \mu_{\text{Sí}} \neq \mu_{\text{No}}$ (hay diferencia entre grupos)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba de Mann-Whitney (U de Wilcoxon)

Estadístico Empleado	Prueba de Mann-Whitney (U de Wilcoxon)
Nombre Parámetro	Valor
Grupo 'Sí' (asistió a reuniones familiares): n	420
Grupo 'Sí': Media	116,109.5
Grupo 'No' (no asistió a reuniones familiares): n	3,660
Grupo 'No': Media	164,447.3
Diferencia de medias (Sí - No)	-48,337.8
Estadístico U (Mann-Whitney)	726,961
Valor-p	0.068

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: No rechazar H_0
- Interpretación en el contexto del problema: Con un nivel de significancia de 0.05, no hay evidencia estadísticamente significativa de diferencia en el ahorro por criar animales entre las personas que asistieron a reuniones familiares (media = 116,109.5) y las que no asistieron (media = 164,447.3). Aunque se observa una diferencia numérica considerable (-48,337.8) donde el grupo que no asistió tiene un mayor ahorro promedio, esta diferencia no alcanza significancia estadística (p-valor = 0.068, ligeramente por encima del umbral de 0.05). Esto indica que la asistencia a reuniones familiares no está asociada con diferencias estadísticamente significativas en el ahorro por criar animales, aunque existe una tendencia numérica que sugiere que quienes no asistieron a reuniones familiares podrían tener mayores ahorros por criar animales.
- Comentarios sobre los hallazgos:
 - ¿Hay evidencia de asociación?: No, no hay evidencia estadísticamente significativa de asociación (p-valor = 0.068 $> 0,05$), aunque el p-valor está cerca del umbral de significancia.
 - ¿En qué dirección?: Sin diferencia significativa (aunque hay una diferencia numérica considerable donde el grupo 'No' tiene mayor media, esta diferencia no alcanza significancia estadística al nivel $\alpha = 0,05$).

- ¿Es débil, moderada o fuerte?: Sin efecto estadísticamente significativo (aunque hay una tendencia numérica que podría ser de interés para análisis posteriores con mayor poder estadístico o niveles de significancia menos estrictos).

La Figura 3 presenta los diagramas de caja (boxplots) comparativos para cada variable cuantitativa según el grupo de reuniones familiares.




Figura 3: Comparación de Variables Cuantitativas según Reuniones Familiares

En la Figura 3 se observan las distribuciones de cada variable cuantitativa separadas por grupo (Sí vs No). Los diagramas de caja permiten visualizar las medianas, cuartiles y valores atípicos de cada grupo, facilitando la comparación visual de las distribuciones.

Para el *Valor mensual por prácticas* (gráfico izquierdo), se observa que ambos grupos presentan distribuciones similares, sin diferencias visuales marcadas entre quienes asistieron a reuniones familiares y quienes no asistieron. Los diagramas de caja se superponen considerablemente, lo cual es consistente con los resultados de la prueba estadística que no encontró diferencias significativas ($p\text{-valor} = 0.948$).

Para el *Ahorro por cultivar* (gráfico central), aunque existe una ligera diferencia numérica en las medianas entre los grupos, los diagramas de caja muestran una superposición considerable, especialmente en los cuartiles. Esto es consistente con los resultados de la prueba de Mann-Whitney que no encontró diferencias estadísticamente significativas ($p\text{-valor} = 0.103$).

Para el *Ahorro por criar animales* (gráfico derecho), se observa que el grupo que no asistió a reuniones familiares presenta una distribución con valores ligeramente más altos, aunque los diagramas de caja aún muestran cierta superposición. Esta observación visual es consistente con los resultados estadísticos que muestran una diferencia numérica pero no estadísticamente significativa al nivel $\alpha = 0,05$ ($p\text{-valor} = 0.068$).

En general, los resultados visuales y estadísticos son consistentes: no se encontró evidencia estadísticamente significativa de asociación entre la asistencia a reuniones familiares y ninguna de las tres variables económicas analizadas al nivel de significancia de 0.05.

2. Análisis de Regresión Múltiple

2.1 Análisis Exploratorio Previo

El modelo de regresión múltiple propuesto tiene como variable respuesta el *Valor mensual por prácticas o pasantías* (Y) y como variables explicativas el *Ahorro por cultivar* (X_1) y el *Ahorro por criar animales* (X_2).

A continuación se presenta el análisis exploratorio de las variables del modelo. La Figura 4 muestra las distribuciones de frecuencia de cada variable del modelo.




Figura 4: Distribución de Variables del Modelo

En la Figura 4 se observa que las tres variables presentan distribuciones claramente sesgadas hacia la derecha. La variable respuesta (Y: Valor mensual por prácticas) muestra una distribución con una cola larga hacia valores altos, con la mayoría de las observaciones concentradas en valores relativamente bajos (alrededor de 80,000 a 2,000,000 pesos), pero con algunos casos con valores mucho más altos (hasta 9,000,000 pesos). Las variables explicativas (X_1 : Ahorro por cultivar y X_2 : Ahorro por criar animales) muestran patrones similares, con distribuciones sesgadas que indican la presencia de algunos valores extremadamente altos. Este tipo de distribución es característico de variables económicas y puede requerir transformaciones logarítmicas para mejorar el cumplimiento de los supuestos del modelo de regresión.

La Figura 5 presenta los diagramas de dispersión entre las variables explicativas y la variable respuesta, incluyendo las rectas de regresión simple para cada relación.

Diagramas de Dispersión: Variables Explicativas vs Variable Respuesta




Figura 5: Diagramas de Dispersión: Variables Explicativas vs Variable Respuesta

En la Figura 5 se observan tendencias positivas claras en ambos diagramas de dispersión, lo cual indica relaciones lineales positivas entre las variables explicativas y la variable respuesta. El diagrama Y vs X_1 muestra una dispersión relativamente amplia alrededor de la recta de regresión, pero con una pendiente positiva clara, sugiriendo que el ahorro por cultivar tiene una asociación positiva con el valor mensual por prácticas. De manera similar, el diagrama Y vs X_2 también muestra una relación positiva, aunque con una pendiente ligeramente menor, lo cual es consistente con los coeficientes de correlación encontrados anteriormente. Ambas relaciones parecen seguir un patrón aproximadamente lineal, lo cual es favorable para el modelo de regresión múltiple propuesto.

2.2 Expectativas del Modelo

Con base en el análisis exploratorio, se espera encontrar:

- Una relación positiva entre el valor mensual por prácticas (Y) y el ahorro por cultivar (X_1), dado que ambas representan ingresos o recursos económicos.
- Una relación positiva entre el valor mensual por prácticas (Y) y el ahorro por criar animales (X_2), por la misma razón.
- Que ambas variables explicativas aporten información relevante para explicar la variabilidad en el valor mensual por prácticas.
- Posible multicolinealidad entre X_1 y X_2 si ambas miden conceptos económicos similares, aunque representan fuentes diferentes.

2.3 Modelo de Regresión

2.3.1 Planteamiento Formal del Modelo

El modelo de regresión múltiple se plantea formalmente como:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

Donde:

- Y = Valor mensual por prácticas o pasantías (variable respuesta)
- X_1 = Ahorro por cultivar (variable explicativa 1)
- X_2 = Ahorro por criar animales (variable explicativa 2)
- β_0 = Intercepto
- β_1 = Coeficiente de regresión para X_1
- β_2 = Coeficiente de regresión para X_2
- ε = Término de error

2.3.2 Matriz de Coeficientes del Modelo

Cuadro 1: Matriz de Coeficientes del Modelo de Regresión Múltiple

Coeficiente	Estimación	Error Estándar	Estadístico t	Valor-p
β_0 (Intercepto)	2,563,461.55	268,708.60	9.540	$6,40 \times 10^{-20}$ ***
β_1 (X_1)	0.1399	0.0192	7.271	$1,39 \times 10^{-12}$ ***
β_2 (X_2)	0.0844	0.0195	4.330	$1,81 \times 10^{-5}$ ***

Cuadro 2: *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

2.3.3 Pruebas de Significancia de Coeficientes Individuales

Para cada coeficiente se plantean las siguientes hipótesis:

- Hipótesis: $H_0 : \beta_i = 0$ (el coeficiente no es significativo) $H_1 : \beta_i \neq 0$ (el coeficiente es significativo)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba t para coeficientes de regresión

Resultados:

- β_0 (Intercepto):
 - Estimación: 2,563,461.55
 - Error estándar: 268,708.60
 - Estadístico t: 9.540
 - Valor-p: $6,40 \times 10^{-20}$
 - Decisión: Rechazar H_0 . El intercepto es significativo.

- Interpretación: El valor esperado del valor mensual por prácticas cuando ambas variables explicativas son cero es de 2,563,461.55 pesos, lo cual es estadísticamente significativo.
- β_1 (Coeficiente para X_1):
 - Estimación: 0.1399
 - Error estándar: 0.0192
 - Estadístico t: 7.271
 - Valor-p: $1,39 \times 10^{-12}$
 - Decisión: Rechazar H_0 . El coeficiente para el ahorro por cultivar es significativo.
 - Interpretación: Manteniendo constante el ahorro por criar animales, un aumento de 1 peso en el ahorro por cultivar se asocia con un aumento promedio de 0.1399 pesos en el valor mensual por prácticas. Esto indica que el ahorro por cultivar tiene un efecto positivo y significativo sobre el valor mensual por prácticas.
- β_2 (Coeficiente para X_2):
 - Estimación: 0.0844
 - Error estándar: 0.0195
 - Estadístico t: 4.330
 - Valor-p: $1,81 \times 10^{-5}$
 - Decisión: Rechazar H_0 . El coeficiente para el ahorro por criar animales es significativo.
 - Interpretación: Manteniendo constante el ahorro por cultivar, un aumento de 1 peso en el ahorro por criar animales se asocia con un aumento promedio de 0.0844 pesos en el valor mensual por prácticas. Esto indica que el ahorro por criar animales tiene un efecto positivo y significativo sobre el valor mensual por prácticas, aunque el efecto es menor que el del ahorro por cultivar.

2.3.4 Prueba de Significancia Global del Modelo

- Hipótesis: $H_0 : \beta_1 = \beta_2 = 0$ (ninguna variable explicativa es útil) $H_1 : \text{Al menos un } \beta_i \neq 0$ (al menos una variable explicativa es útil)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba F global

Estadístico Empleado	Prueba F global
Fórmula del estadístico	$F = \frac{MSR}{MSE} = \frac{R^2/k}{(1-R^2)/(n-k-1)}$
Nombre Parámetro	Valor
Estadístico F	40.77
Grados de libertad (numerador)	2
Grados de libertad (denominador)	497
Valor-p	$< 2,2 \times 10^{-16}$
R^2 (coeficiente de determinación)	0.141
R^2 ajustado	0.1375
Error estándar residual	4,031,070

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: Rechazar H_0
- Conclusión: Con un nivel de significancia de 0.05, la evidencia sugiere que el modelo es significativo globalmente. Al menos una variable explicativa aporta información relevante para explicar la variabilidad en el valor mensual por prácticas. El modelo explica el 14.1 % de la variabilidad total ($R^2 = 0.141$).

2.3.5 Análisis de Varianza (ANOVA)

- Hipótesis: H_0 : Todos los coeficientes de regresión son cero (modelo no útil)
 H_1 : Al menos un coeficiente de regresión es diferente de cero
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: χ^2 / Prueba F

Cuadro 3: Tabla ANOVA del Modelo de Regresión

Fuente	gl	Suma de Cuadrados	Cuadrados Medios	F	Valor-p
X ₁	1	1,020,488,415,971,762	1,020,488,415,971,762	62.80	$1,51 \times 10^{-15}$ ***
X ₂	1	304,601,872,025,046	304,601,872,025,046	18.75	$1,81 \times 10^{-5}$ ***
Residuales	497	8,076,013,748,592,473	16,249,524,645,055.3	-	-

Cuadro 4: *

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: Rechazar H_0 para ambas variables explicativas
- Interpretación: La tabla ANOVA descompone la variabilidad total en variabilidad explicada por cada variable explicativa y variabilidad no explicada (residual). Tanto X₁ como X₂ son significativos individualmente (X₁: F = 62.80, p-valor = $1,51 \times 10^{-15}$; X₂: F = 18.75, p-valor = $1,81 \times 10^{-5}$), lo que confirma que ambas variables explicativas aportan información relevante al modelo. El ahorro por cultivar (X₁) aporta más variabilidad explicada (Suma de Cuadrados = 1,020,488,415,971,762) que el ahorro por criar animales (X₂: Suma de Cuadrados = 304,601,872,025,046), lo cual es consistente con el mayor coeficiente de correlación encontrado entre Y y X₁ en el análisis de correlación.

2.4 Validación de Supuestos

Se evaluaron gráficamente y analíticamente los supuestos del modelo de regresión múltiple: linealidad, independencia, homocedasticidad y normalidad de los errores.

2.4.1 Supuesto de Linealidad

- Hipótesis: H_0 : La relación entre variables es lineal entre variables no es lineal H_1 : La relación
- Nivel de significancia: $\alpha = 0,05$
- Método de Evaluación: Inspección gráfica de residuos vs valores ajustados

Para evaluar el supuesto de linealidad, se analizan los gráficos de residuos vs valores ajustados. La Figura 6 presenta los gráficos de residuos estandarizados y residuos vs valores ajustados.




Figura 6: Validación de Linealidad: Gráficos de Residuos

En la Figura 6 se observa que los residuos estandarizados (gráfico izquierdo) se distribuyen de manera relativamente aleatoria alrededor de la línea horizontal en cero, sin mostrar patrones sistemáticos claros como curvas o tendencias. La línea de suavizado (en verde) muestra una ligera variación pero sin patrones marcados de no linealidad. El gráfico de residuos vs valores ajustados (gráfico derecho) también muestra un patrón relativamente aleatorio, aunque con una mayor dispersión en los valores más altos de los valores ajustados. Esta mayor variabilidad en los valores altos podría indicar una ligera heterocedasticidad o podría ser simplemente un efecto del menor número de observaciones en esos rangos. En general, el supuesto de linealidad se cumple aproximadamente, aunque se recomienda considerar transformaciones si se detectan otros problemas en los supuestos.

2.4.2 Supuesto de Independencia

- Hipótesis: H_0 : Los residuos son independientes (no hay autocorrelación) H_1 : Los residuos no son independientes (hay autocorrelación)

- Nivel de significancia: $\alpha = 0,05$

- Estadístico de Prueba: Prueba de Durbin-Watson

Estadístico Empleado	Prueba de Durbin-Watson
Nombre Parámetro	Valor
Estadístico DW	1.9726
Valor-p	0.752

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$

- Decisión: No rechazar H_0

- Conclusión: No hay evidencia de autocorrelación en los residuos. El supuesto de independencia se cumple.

Para evaluar el supuesto de independencia de los residuos, se analiza la secuencia de residuos a lo largo del orden de observación. La Figura 7 muestra los residuos estandarizados vs el orden de observación.




Figura 7: Validación de Independencia: Residuos vs Orden

En la Figura 7 se observa que los residuos estandarizados fluctúan de manera aleatoria alrededor de la línea horizontal en cero a lo largo del orden de observación, sin mostrar patrones sistemáticos como tendencias crecientes o decrecientes, ciclos o agrupamientos. Esta distribución aleatoria indica que no hay evidencia de autocorrelación en los residuos, lo cual es consistente con los resultados de la prueba de Durbin-Watson ($DW = 1.9726$, $p\text{-valor} = 0.752$). El supuesto de independencia se cumple, lo cual es esperado dado que las observaciones provienen de diferentes hogares y no deberían estar correlacionadas temporal o espacialmente de manera sistemática.

2.4.3 Supuesto de Homocedasticidad

- Hipótesis: H_0 : Varianza constante de los errores (homocedasticidad) H_1 : Varianza no constante de los errores (heterocedasticidad)
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba de Breusch-Pagan

Estadístico Empleado	Prueba de Breusch-Pagan
Nombre Parámetro	Valor
Estadístico LM	0.0679
Valor-p	0.967

- Regla de decisión: Rechazar H_0 si p-valor $< 0,05$
- Decisión: No rechazar H_0
- Conclusión: No hay evidencia de heterocedasticidad. El supuesto de homocedasticidad se cumple.

Para evaluar el supuesto de homocedasticidad (varianza constante de los errores), se utiliza el gráfico de escala-localización, el cual muestra la raíz cuadrada del valor absoluto de los residuos estandarizados vs los valores ajustados. La Figura 8 presenta este gráfico.




Figura 8: Validación de Homocedasticidad: Gráfico de Escala-Localización

En la Figura 8 se observa que la línea de suavizado (en rojo) se mantiene relativamente horizontal a lo largo del rango de valores ajustados, con algunas variaciones menores pero sin una tendencia clara de aumento o disminución sistemática. Si existiera heterocedasticidad, se esperaría ver una tendencia marcada en esta línea, ya sea creciente (indicando que la varianza aumenta con los valores ajustados) o decreciente (indicando que la varianza disminuye). La ausencia de una tendencia clara, junto con el resultado de la prueba

de Breusch-Pagan ($LM = 0.0679$, $p\text{-valor} = 0.967$), confirma que el supuesto de homocedasticidad se cumple. Esto indica que la varianza de los errores es constante a lo largo de todos los valores de las variables explicativas, lo cual es necesario para que los intervalos de confianza y las pruebas de hipótesis sean válidos.

2.4.4 Supuesto de Normalidad de los Errores

- Hipótesis: H_0 : Los errores siguen una distribución normal H_1 : Los errores no siguen una distribución normal
- Nivel de significancia: $\alpha = 0,05$
- Estadístico de Prueba: Prueba de Shapiro-Wilk

Estadístico Empleado	Prueba de Shapiro-Wilk
Nombre Parámetro	Valor
Estadístico W	0.9123
Valor-p	$2,03 \times 10^{-16}$

- Regla de decisión: Rechazar H_0 si $p\text{-valor} < 0,05$
- Decisión: Rechazar H_0
- Conclusión: Los residuos no siguen una distribución normal. El supuesto de normalidad no se cumple.

Para evaluar el supuesto de normalidad de los errores, se utilizan tanto el gráfico Q-Q (quantil-quantil) como el histograma de los residuos estandarizados. La Figura 9 muestra ambos gráficos.

Q Plot de residuos estandarizados




Figura 9: Validación de Normalidad: Q-Q Plot e Histograma

En la Figura 9 se observa claramente que los residuos no siguen una distribución normal. En el Q-Q plot (gráfico izquierdo), los puntos se desvían notablemente de la línea

de referencia (en rojo), especialmente en las colas de la distribución. Los valores en los extremos inferiores (cuantiles teóricos negativos) y superiores (cuantiles teóricos positivos) se alejan significativamente de la línea, indicando que la distribución tiene colas más pesadas que la distribución normal. El histograma (gráfico derecho) confirma este hallazgo, mostrando una distribución que, aunque parece aproximadamente simétrica alrededor de cero, presenta colas más pesadas y posiblemente una forma más puntiaguda (leptocúrtica) o más plana (platicúrtica) que la distribución normal teórica (superpuesta en rojo). Estos hallazgos visuales son consistentes con el resultado de la prueba de Shapiro-Wilk ($W = 0.9123$, $p\text{-valor} < 0,001$), que rechaza la hipótesis nula de normalidad. Sin embargo, dado el tamaño de muestra grande ($n = 500$) y el cumplimiento de los demás supuestos críticos (independencia y homocedasticidad), el modelo sigue siendo válido debido al Teorema del Límite Central, aunque los intervalos de confianza pueden ser menos precisos que si se cumpliera completamente el supuesto de normalidad.

2.4.5 Tabla Resumen de Validación de Supuestos

Cuadro 5: Tabla Resumen de Validación de Supuestos del Modelo

Supuesto	Prueba	Estadístico	Valor-p	Decisión	Cumplimiento
Linealidad	Inspección gráfica	N/A (gráfico)	N/A	Evaluar gráficamente	Aproximadamente
Independencia	Durbin-Watson	1.9726	0.752	No rechazar H_0	Sí
Homocedasticidad	Breusch-Pagan	0.0679	0.967	No rechazar H_0	Sí
Normalidad de errores	Shapiro-Wilk	0.9123	$2,03 \times 10^{-16}$	Rechazar H_0	No

Comentarios sobre cumplimiento de supuestos:

- **Linealidad:** La inspección gráfica de los residuos vs valores ajustados sugiere un patrón relativamente aleatorio alrededor de cero, indicando que el supuesto de linealidad se cumple aproximadamente.
- **Independencia:** La prueba de Durbin-Watson no muestra evidencia de autocorrelación ($p\text{-valor} = 0.752$). El supuesto de independencia se cumple.
- **Homocedasticidad:** La prueba de Breusch-Pagan no muestra evidencia de heterocedasticidad ($p\text{-valor} = 0.967$). El supuesto de homocedasticidad se cumple.
- **Normalidad:** La prueba de Shapiro-Wilk indica que los residuos no siguen una distribución normal ($p\text{-valor} < 0,001$). El supuesto de normalidad **no se cumple**. Esta violación puede afectar los intervalos de confianza y las pruebas de hipótesis, especialmente en muestras pequeñas. Sin embargo, dado el tamaño de muestra ($n = 500$), los resultados del modelo son robustos a esta violación debido al Teorema del Límite Central.

2.5 Transformaciones

Evaluando la necesidad de transformaciones, se detectó una violación del supuesto de normalidad de los errores. Se consideró aplicar una transformación logarítmica a las variables.

Opción evaluada: Transformación logarítmica

$$\log(Y + 1) = \beta_0 + \beta_1 \log(X_1 + 1) + \beta_2 \log(X_2 + 1) + \varepsilon$$

Justificación técnica: Las variables económicas suelen tener distribuciones sesgadas que se normalizan con transformación logarítmica. Esta transformación también puede ayudar a estabilizar la varianza de los errores.

Resultados del modelo transformado:

- Prueba de Breusch-Pagan (modelo transformado): Valor-p = 0.990
- Prueba de Shapiro-Wilk (modelo transformado): Valor-p < 0,001

Decisión técnica: La transformación logarítmica no mejora significativamente el cumplimiento del supuesto de normalidad. Aunque mejora la homocedasticidad, la normalidad sigue siendo rechazada.

Dado que:

- El tamaño de muestra es grande ($n = 500$), lo que proporciona robustez a la violación del supuesto de normalidad
- Los supuestos de independencia y homocedasticidad se cumplen
- La transformación logarítmica no resuelve completamente el problema de normalidad

Se recomienda mantener el modelo original sin transformaciones, reconociendo la violación del supuesto de normalidad pero considerando que el modelo es robusto dado el tamaño de muestra y el cumplimiento de los demás supuestos críticos.

Conclusiones

- Se encontró evidencia de correlaciones positivas entre todas las variables analizadas, siendo la correlación entre el valor mensual por prácticas y el ahorro por cultivar la más fuerte ($r = 0.3295$, moderada).
- El modelo de regresión múltiple es significativo globalmente ($F = 40.77$, $p < 2,2 \times 10^{-16}$), explicando el 14.1 % de la variabilidad en el valor mensual por prácticas ($R^2 = 0.141$, R^2 ajustado = 0.1375).
- Ambas variables explicativas (ahorro por cultivar y ahorro por criar animales) son significativas individualmente y aportan información relevante al modelo.
- Los supuestos de linealidad, independencia y homocedasticidad se cumplen. El supuesto de normalidad no se cumple, pero esto no invalida los resultados debido al tamaño de muestra y al cumplimiento de los demás supuestos críticos.
- El modelo estimado es:

$$\hat{Y} = 2,563,461,55 + 0,1399X_1 + 0,0844X_2$$

donde:

- El intercepto ($\beta_0 = 2,563,461.55$) representa el valor esperado del valor mensual por prácticas cuando ambas variables explicativas son cero, y es estadísticamente significativo ($t = 9.540$, $p < 6,40 \times 10^{-20}$).
- Manteniendo constante el ahorro por criar animales, un aumento de 1 peso en el ahorro por cultivar (X_1) se asocia con un aumento promedio de 0.1399 pesos en el valor mensual por prácticas. Este coeficiente es estadísticamente significativo ($t = 7.271$, $p < 1,39 \times 10^{-12}$).
- Manteniendo constante el ahorro por cultivar, un aumento de 1 peso en el ahorro por criar animales (X_2) se asocia con un aumento promedio de 0.0844 pesos en el valor mensual por prácticas. Este coeficiente es estadísticamente significativo ($t = 4.330$, $p < 1,81 \times 10^{-5}$), aunque el efecto es menor que el de X_1 .